

**ANALISIS CLUSTER AIR QUALITY
DI BERBAGAI NEGARA TAHUN 2023**



Disusun oleh:

1. Nicholas Evan Sitanggang - 5026231146
2. Kayla Putri Maharani - 5026231158
3. Tahiyyah Mufhimah - 5026231170
4. Sahilah Amru Yumnatusta - 5026231182

**DEPARTEMEN SISTEM INFORMASI
FAKULTAS TEKNOLOGI ELEKTRO DAN INFORMATIKA CERDAS
TAHUN AJARAN 2023-2024
INSTITUT TEKNOLOGI SEPULUH NOPEMBER**

Ringkasan Perbaikan *Final Project* ADD A

Semester Ganjil 2024-2025

Kelompok : Kelompok 11

Anggota (Nama dan NRP) :

1. Nicholas Evan Sitanggang - 5026231146
2. Kayla Putri Maharani - 5026231151
3. Tahiyah Mufhimah - 5026231170
4. Sahilah Amru Yumnatusta - 5026231182

Revisi yang didasarkan inisiatif kelompok Kami sendiri, yaitu :

No	Perbaikan/Revisi	Halaman
1	Statistika Deskriptif dan Visualisasi Data	12
2	Visualisasi Clustering Data	23
3	Cluster profiling & analysis	22

DAFTAR ISI

Ringkasan Perbaikan <i>Final Project</i> ADD A.....	1
DAFTAR ISI	2
DAFTAR GAMBAR	4
DAFTAR TABEL.....	4
BAB 1.....	5
PENDAHULUAN.....	5
1. 1 Tema.....	5
1.2 Latar Belakang Masalah.....	5
1.4 Tujuan.....	6
1.5 Sumber Data	6
BAB 2.....	7
METODOLOGI PENELITIAN	7
2.1 Data Cleaning	7
2.2 Principal Component Analysis (PCA)	7
2.3 K-Means Clustering	8
BAB 3.....	9
PEMBAHASAN.....	9
3.1 Deskripsi Data	9
3.2 Persiapan Data	9
3.2.1 Pengumpulan Data	9
3.2.2 Pembersihan data.....	10
3.3 Statistika Deskriptif dan Visualisasi Data	11
3.3.1 Statistika Deskriptif dan Visualisasi Data PM 2.5	12
3.3.2 Statistika Deskriptif dan Visualisasi Data PM 10	13
3.3.3 Statistika Deskriptif dan Visualisasi Data NO2	13
3.3.4 Statistika Deskriptif dan Visualisasi Data SO2	14
3.3.5 Statistika Deskriptif dan Visualisasi Data CO	14
3.3.6 Statistika Deskriptif dan Visualisasi Data O3	15

3.3.7 Statistika Deskriptif dan Visualisasi Data <i>Temperature</i>	15
3.3.8 Statistika Deskriptif dan Visualisasi Data Humidity	16
3.3.9 Statistika Deskriptif dan Visualisasi Data Wind Speed	16
3.4 Pengolahan Data	17
3.4.1 Normalisasi Data dengan Min Max Scaling.....	17
3.4.2 Mencari Cluster dengan Elbow Method.....	19
3.4.3 Mencari Cluster dengan Silhouette Coefficient	20
3.4.4 Mencari <i>Cluster</i> dengan <i>KMeans</i>	21
3.4.5 Visualisasi <i>Clustering Data</i>	22
3.4.6 <i>Cluster Profiling & Analysis</i>	23
3.4.6 <i>Principal Component Analysis</i>	24
3.4.7 <i>Clustering on Principal Components</i>	29
3.4.8 Identifikasi Polusi Tertinggi.....	31
3.4.9 Identifikasi Polutan di Tiap Cluster.....	31
BAB 4	34
KESIMPULAN	34
DAFTAR PUSTAKA	35

DAFTAR GAMBAR

Gambar 2.2 Rumus Matriks Kovarians	8
Gambar 3.2. 1 Dataset	10
Gambar 3.2. 2 Pembersihan Data	11
Gambar 3.3. 1 Statistik PM2.5	12
Gambar 3.3. 2 Statistik PM10	13
Gambar 3.3. 3 Statistik NO2	13
Gambar 3.3. 4 Statistik SO2	14
Gambar 3.3. 5 Statistik CO	14
Gambar 3.3. 6 Statistik O3	15
Gambar 3.3. 7 Statistik Temperature.....	15
Gambar 3.3. 8 Statistika Humidity	16
Gambar 3.3. 9 Statistika Wind Speed.....	16
Gambar 3.4.1. 1 Hasil Normalisasi	17
Gambar 3.4.1. 2 Scatterplot setelah dinormalisasi	18
Gambar 3.4.2 Hasil Elbow Method.....	19
Gambar 3.4.3 Hasil Silhouette Coefficient	20
Gambar 3.4.4 KMeans.....	21
Gambar 3.4.6. 1 PCA Features	25
Gambar 3.4.6. 2 Varians.....	25
Gambar 3.4.6. 3 Kontribusi Relatif	26
Gambar 3.4.6. 4 Hasil Penggunaan Regresi Linear	27

DAFTAR TABEL

Tabel 3.4.7 Hasil Perbandingan Clustering PCA	30
Tabel 3.4.5 Hasil Custering	24

BAB 1

PENDAHULUAN

1. 1 Tema

Pada final project kali ini, kami mengambil tema mengenai lingkungan, *Global Air Quality*. Dataset *Global Air Quality Data* menyajikan kumpulan data komprehensif mengenai pengukuran kualitas udara dari berbagai kota besar di seluruh dunia. Dataset ini mencakup indikator lingkungan penting seperti partikel udara (PM2.5 dan PM10), nitrogen dioksida (NO₂), sulfur dioksida (SO₂), karbon monoksida (CO), dan ozon (O₃). Selain itu, terdapat juga data meteorologi seperti suhu, kelembaban, dan kecepatan angin.

1.2 Latar Belakang Masalah

Kualitas udara merupakan salah satu indikator penting dalam mengukur kesehatan lingkungan dan kesejahteraan manusia. Dalam beberapa dekade terakhir, peningkatan aktivitas manusia, seperti industrialisasi, urbanisasi, dan penggunaan bahan bakar fosil, telah menyebabkan polusi udara menjadi isu global yang signifikan. Dampak dari polusi udara tidak hanya dirasakan oleh lingkungan, tetapi juga mempengaruhi kesehatan manusia, seperti meningkatnya risiko penyakit pernapasan, kardiovaskular, hingga kematian dini.

Data kualitas udara global yang mencakup berbagai polutan, seperti PM2.5 (partikel halus berdiameter kurang dari 2.5 mikrometer), PM10 (partikel berdiameter kurang dari 10 mikrometer), Nitrogen dioksida (NO₂), Sulfur dioksida (SO₂), Karbon monoksida (CO), dan ozon (O₃), serta faktor meteorologi seperti suhu, kelembapan, dan kecepatan angin, memberikan wawasan berharga mengenai distribusi polutan di berbagai negara.

Dengan total 1.000 catatan, dataset ini memiliki beberapa tujuan utama, yaitu menganalisis tren kualitas udara di berbagai wilayah secara global. Dataset ini dikumpulkan dari berbagai kota besar di dunia untuk digunakan oleh peneliti, ilmuwan data, dan pembuat kebijakan. Bagi peneliti, dataset ini dapat menjadi dasar untuk mempelajari pola polusi dan faktor yang mempengaruhinya. Bagi ilmuwan data, dataset ini membuka peluang untuk pengembangan model prediktif terkait kualitas udara. Sementara itu, pembuat kebijakan dapat memanfaatkan data ini untuk merancang kebijakan lingkungan yang lebih efektif demi meningkatkan kualitas udara dan kesehatan masyarakat. Namun, data ini memiliki dimensi yang tinggi dan pola yang kompleks, sehingga memerlukan metode analisis yang efektif untuk mengidentifikasi pola dan hubungan di dalamnya.

Dalam konteks ini, metode clustering seperti K-Means dan teknik *Principal Component Analysis* (PCA) menjadi penting, untuk mengelompokkan data berdasarkan kesamaan karakteristik. Dengan pendekatan ini, kita dapat memahami faktor-faktor utama yang mempengaruhi tingkat polusi udara, mengidentifikasi negara dengan polusi tertinggi, dan memberikan rekomendasi untuk upaya mitigasi polusi di tingkat global.

Penelitian ini bertujuan untuk menganalisis data kualitas udara dari berbagai negara pada tahun 2023, menggunakan metode clustering untuk memahami distribusi polusi dan mengidentifikasi faktor-faktor yang mempengaruhi konsentrasi polutan. Melalui analisis dataset ini, diharapkan akan muncul wawasan yang mendalam mengenai kondisi kualitas udara global. Pengetahuan tersebut dapat mendukung inisiatif untuk menciptakan lingkungan yang lebih bersih dan sehat bagi generasi saat ini maupun masa depan.

1.3 Rumusan Masalah

Berdasarkan latar belakang yang telah kami paparkan di atas, kelompok kami menyusun rumusan masalah sebagai berikut:

- Apakah kecepatan angin (*wind speed*), suhu (*temperature*), dan kelembaban udara (*humidity*) mempengaruhi konsentrasi atau nilai dari polutan di udara?
- Bagaimana distribusi rata-rata polutan utama (PM10, PM2.5, NO2, CO, dan O3) di setiap cluster?
- Negara mana yang tercatat memiliki tingkat polusi udara tertinggi di dunia, berdasarkan data konsentrasi polutan utama?

1.4 Tujuan

Berdasarkan rumusan masalah yang telah disusun, kelompok kami merumuskan beberapa tujuan utama dari penelitian ini sebagai berikut:

- Untuk mengetahui apakah kecepatan angin (*wind speed*), suhu (*temperature*), dan kelembaban udara (*humidity*) mempengaruhi konsentrasi atau nilai dari polutan udara, seperti PM10, PM2.5, NO2, dan CO, O3.
- Untuk menganalisis rata-rata konsentrasi polutan utama (PM10, PM2.5, NO2, CO, dan O3) di setiap cluster untuk memahami tingkat polusi udara.
- Untuk mengidentifikasi negara yang memiliki tingkat polusi udara tertinggi di dunia, berdasarkan data konsentrasi polutan utama seperti PM10, PM2.5, NO2, CO, dan O3.

1.5 Sumber Data

Data yang digunakan dalam penelitian ini berasal dari Global Air Quality Data, sebuah dataset yang tersedia di platform Kaggle. Dataset ini disusun oleh WAQI dan dapat diakses melalui tautan berikut: [Global Air Quality Dataset](#)

BAB 2

METODOLOGI PENELITIAN

2.1 Data Cleaning

Data cleaning (pembersihan data), dikenal juga sebagai *data cleansing* atau *data scrubbing*, adalah proses mengidentifikasi dan mengoreksi atau membuang data yang salah dari *dataset*. Data yang dibersihkan bisa berupa data yang inkonsisten, inakurat, duplikat, salah format, atau eror lain yang dapat mengganggu proses analisis data selanjutnya.

Proses *data cleaning* merupakan tahapan yang penting dalam mempersiapkan data sebelum masuk ke tahap analisis data atau pemodelan *machine learning* karena data masukan sangat menentukan kualitas dari hasil pengolahan data.

2.2 Principal Component Analysis (PCA)

Principal Component Analysis (PCA) adalah teknik yang digunakan untuk menyederhanakan suatu data, dengan cara mentransformasi linear sehingga terbentuk sistem koordinat baru dengan variansi maksimum. PCA dapat digunakan untuk mereduksi dimensi suatu data tanpa mengurangi karakteristik data tersebut secara signifikan.

Metode ini mengubah dari sebagian besar variabel asli yang saling berkorelasi menjadi satu himpunan variabel baru yang lebih kecil dan saling bebas (tidak berkorelasi lagi). Prinsip dasar dari algoritma *Principal Component Analysis* adalah mengurangi satu set data namun tetap mempertahankan sebanyak mungkin variasi dalam set data tersebut. Cara kerja PCA dapat dilihat sebagai berikut:

A. Standarisasi Data

Sebelum digunakan untuk pengujian PCA, data harus distandarisasi terlebih dahulu. Standarisasi dapat dilakukan dengan berbagai cara, salah satunya adalah dengan menggunakan MinMax Scaler seperti yang kita gunakan dalam penelitian ini.

B. Matriks Kovarians

Matriks kovarians adalah matriks simetris yang menunjukkan varians dan kovarians antara berbagai fitur dalam satu set data. Matriks ini digunakan untuk mengukur informasi bersama antara berbagai fitur dan reduksi dimensionalitas. Matriks kovarians sering digunakan dalam PCA untuk memahami hubungan antar variabel.

Rumus :

$$\Sigma(x_i - x_{avg})(y_i - y_{avg})/(n - 1)$$

Gambar 2.2. 1 Rumus Matriks Kovarians

C. Eigen Decomposition

Eigen Decomposition atau dekomposisi eigen adalah metode yang digunakan dalam aljabar linear untuk memecah matriks persegi menjadi komponen yang lebih sederhana yang disebut nilai eigen dan vektor eigen. Nilai eigen merupakan nilai numerik yang menjadi ciri suatu matriks, sedangkan vektor eigen merupakan vektor yang arahnya tetap tidak berubah saat matriks diterapkan. Proses ini membantu kita memahami bagaimana matriks berperilaku dan bagaimana ia mengubah data. Dekomposisi Eigen ini digunakan dalam metode PCA karena metode ini dapat mengurangi dimensionalitas data dan menyoroti elemen yang paling penting untuk analisis.

Rumus:

$$\text{Matriks kovarians} \times \text{Vektor eigen} = \text{Nilai eigen} \times \text{vektor eigen}$$

2.3 K-Means Clustering

K-Means Clustering adalah suatu metode penganalisaan data atau metode Data Mining yang melakukan proses pemodelan unsupervised learning dan menggunakan metode yang mengelompokkan data berbagai partisi. K-Means Clustering memiliki objective yaitu meminimalisasi object function yang telah diatur pada proses clusterisasi. Dengan cara minimalisasi variasi antar 1 cluster dengan maksimalisasi variasi dengan data di cluster lainnya. Tujuan dari K-Means Clustering ini sendiri adalah untuk meminimalisasikan fungsi objective yang telah di set dalam proses clustering. Penerapan K-Means Clustering adalah sebagai berikut:

- a. Menentukan jumlah cluster
- b. Secara acak mendistribusikan data cluster
- c. Menghitung rata rata dari data yang ada di cluster.
- d. Menggunakan langkah baris 3 kembali sesuai nilai threshold
- e. Menghitung jarak antara data dan nilai centroid (K-means clustering)
- f. Distance space dapat diimplementasikan untuk menghitung jarak data dan centroid. Contoh penghitungan jarak yang sering digunakan adalah manhattan/city block distance.

BAB 3

PEMBAHASAN

3.1 Deskripsi Data

Dalam penelitian ini, data yang digunakan berasal dari Global Air Quality Data, sebuah dataset yang disusun oleh WAQI dan tersedia di platform Kaggle. Dataset ini mencakup informasi mengenai kualitas udara di berbagai lokasi di seluruh dunia, yang terdiri dari beberapa variabel utama. Variabel tersebut meliputi tanggal dan waktu pengukuran, lokasi yang mencakup nama kota dan negara, serta konsentrasi berbagai polutan seperti PM2.5 (partikel halus berdiameter kurang dari 2.5 mikrometer), PM10 (partikel berdiameter kurang dari 10 mikrometer), NO2 (nitrogen dioksida), SO2 (sulfur dioksida), CO (karbon monoksida), dan O3 (ozon).

Selain itu, dataset ini juga mencatat variabel lingkungan seperti suhu udara (Temperature), kelembapan (Humidity), dan kecepatan angin (Wind Speed). Variabel-variabel tersebut memberikan gambaran komprehensif mengenai kondisi kualitas udara dan faktor lingkungan yang mempengaruhinya di berbagai kota dan negara, sehingga dapat digunakan untuk analisis lebih lanjut terkait kualitas udara dan lingkungan.

3.2 Persiapan Data

3.2.1 Pengumpulan Data

Tahap pertama dalam pengolahan data adalah mengimpor pustaka-pustaka yang diperlukan untuk analisis dan manipulasi data. Pustaka yang digunakan meliputi **pandas** yang berfungsi untuk melakukan analisis dan manipulasi data, **matplotlib.pyplot** untuk menyajikan visualisasi data, **numpy** yang menyediakan array multidimensi untuk operasi numerik, **MinMaxScaler** dari **sklearn.preprocessing** yang digunakan untuk melakukan normalisasi data, **KMeans** dari **sklearn.cluster** yang digunakan untuk melakukan clustering, **PCA** (Principal Component Analysis) dari **sklearn.decomposition** yang berfungsi untuk mengurangi dimensi dataset, **silhouette_score** dari **sklearn.metrics** yang digunakan untuk mengevaluasi kualitas clustering, serta pustaka **seaborn** yang mempermudah visualisasi data statistik.

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import MinMaxScaler
from sklearn.cluster import KMeans
from sklearn.decomposition import PCA
from sklearn.metrics import silhouette_score
import matplotlib.pyplot as plt
import seaborn as sns
```

```
df = pd.read_excel('/content/drive/MyDrive/ColabNotebooks/
global_air_quality_data_1000.xlsx')
df
```

Berdasarkan kode yang dijalankan, hasil yang diperoleh menunjukkan bahwa dataset ini terdiri dari 999 baris data dan 9 kolom variabel. Variabel-variabel dalam dataset ini meliputi City, Country, Date, PM2.5, PM10, NO2, SO2, CO, O3, Temperature (suhu), Humidity (kelembapan), dan Wind Speed (kecepatan angin). Setiap baris merepresentasikan pengukuran parameter kualitas udara pada kondisi tertentu.

	City	Country	Date	PM2.5	PM10	NO2	SO2	CO	O3	Temperature	Humidity	Wind Speed
0	Bangkok	Thailand	2023-03-19	86.57	25.19	99.88	30.63	4.46	36.29	17.67	59.35	13.76
1	Istanbul	Turkey	2023-02-16	50.63	97.39	48.14	8.71	3.40	144.16	3.46	67.51	6.36
2	Rio de Janeiro	Brazil	2023-11-13	130.21	57.22	98.51	9.92	0.12	179.31	25.29	29.30	12.87
3	Mumbai	India	2023-03-16	119.70	130.52	10.96	33.03	7.74	38.65	23.15	99.97	7.71
4	Paris	France	2023-04-04	55.20	36.62	76.85	21.85	2.00	67.09	16.02	90.28	14.16
...	...	...	...	...	...	...	...	...	...	...	...	...
994	Johannesburg	South Africa	2023-06-25	44.49	152.25	58.04	19.66	4.17	163.08	39.50	43.55	17.65
995	Istanbul	Turkey	2023-09-16	146.60	21.99	83.75	33.54	8.85	124.04	37.31	54.85	9.59
996	Berlin	Germany	2023-04-24	76.31	99.69	46.84	19.50	8.84	58.38	-8.40	61.53	14.72
997	Moscow	Russia	2023-07-28	132.44	49.06	29.60	46.72	8.84	119.14	20.98	40.65	1.36
998	Beijing	China	2023-03-02	93.46	66.86	46.10	7.51	9.60	145.11	29.73	11.91	19.79

Gambar 3.2. 1 Dataset

3.2.2 Pembersihan data

Pada tahap ini, data akan dibersihkan untuk memastikan kualitas dan validitasnya. Pembersihan data mencakup proses menghapus data kosong, memperbaiki nilai yang salah, dan menghapus data yang tidak relevan. Namun, jika tidak ditemukan data yang tidak valid, tidak relevan, atau kosong, proses pembersihan tidak perlu dilakukan dan dapat langsung dilanjutkan ke tahap perhitungan.

Untuk memeriksa apakah dataset memiliki kolom data yang berisi nilai null pada sumbu x dan sumbu y, menggunakan rumus berikut:

```
df.isnull().any(axis=1).sum()
df.isnull().any(axis=0)
```

Berdasarkan hasil pemeriksaan dengan metode di atas, dapat dipastikan bahwa dataset ini tidak memiliki nilai kosong di seluruh kolom maupun baris. Hal ini terlihat dari output yang ditampilkan, di mana semua kolom memiliki nilai **False**. Nilai **False** ini menandakan bahwa tidak ada satu pun nilai kosong pada kolom tersebut. Karena tidak ada nilai kosong yang ditemukan, tidak ada baris yang perlu dihapus atau dilakukan imputasi.

```

0
City      False
Country   False
Date       False
PM2.5     False
PM10      False
NO2       False
SO2       False
CO        False
O3        False
Temperature False
Humidity  False
Wind Speed False

dtype: bool

```

Gambar 3.2. 2 Pembersihan Data

3.3 Statistika Deskriptif dan Visualisasi Data

Analisis data dapat lebih mudah dilakukan apabila kita mengetahui statistik deskriptif dari data yang digunakan. Oleh karena itu, dapat dimasukkan kode di bawah untuk melihat visualisasi dari masing-masing variabel yang kita olah.

Analisis data akan dapat lebih mudah dilakukan apabila melihat statistik deskriptif dan visualisasi untuk setiap variabel. Hal ini bertujuan untuk memahami distribusi, pola, dan karakteristik data yang digunakan sehingga analisis dapat dilakukan dengan lebih terarah. Oleh karena itu, kami menggunakan kode di bawah ini untuk melihat visualisasi dari masing-masing variabel yang kita olah.

```

for column in df.select_dtypes(include=[np.number]).columns:
    plt.figure(figsize=(15, 5))
    # Histogram
    plt.subplot(1, 3, 1)
    sns.histplot(df[column], kde=True, bins=10)
    plt.title(f'Histogram of {column}')


    # Boxplot
    plt.subplot(1, 3, 2)
    sns.boxplot(x=df[column])
    plt.title(f'Boxplot of {column}')

```

```
# Scatter plot
if len(df.select_dtypes(include=[np.number]).columns) > 1:
    plt.subplot(1, 3, 3)
    for other_column in df.select_dtypes(include=[np.number]).columns:
        if column != other_column:
            sns.scatterplot(x=df[column], y=df[other_column])
            plt.title(f'Scatter plot {column} vs {other_column}')

plt.tight_layout()
plt.show()
```


3.3.1 Statistika Deskriptif dan Visualisasi Data PM 2.5



Gambar 3.3. 1 Statistika PM2.5

Histogram di atas menunjukkan distribusi variabel PM2.5 dengan nilai yang tersebar merata antara 0 hingga 150, tanpa puncak yang signifikan. Boxplot menunjukkan median PM2.5 di sekitar 80, dengan sebagian besar data berada dalam rentang 40 hingga 120, serta adanya beberapa outlier yang menunjukkan kondisi polusi ekstrem. Scatter plot antara PM2.5 dan Wind Speed memperlihatkan persebaran nilai PM2.5 yang tidak memiliki pola jelas terhadap kecepatan angin, sementara ukuran dan warna titik menunjukkan bahwa PM10 cenderung berkorelasi positif dengan PM2.5. Visualisasi ini mengindikasikan variasi polusi yang cukup kompleks tanpa pengaruh dominan dari kecepatan angin.


3.3.2 Statistika Deskriptif dan Visualisasi Data PM 10



Gambar 3.3. 2 Statistika PM10

Histogram menunjukkan distribusi PM10 dengan nilai tersebar antara 0 hingga 200, di mana frekuensi tertinggi terlihat pada rentang sekitar 100 hingga 125. Boxplot mengindikasikan median PM10 berada di sekitar nilai 100, dengan data tersebar antara 25 hingga 175, serta beberapa outlier yang mencerminkan kondisi polusi tinggi. Scatter plot antara PM10 dan Wind Speed menunjukkan bahwa nilai PM10 tersebar merata pada berbagai kecepatan angin, sementara warna dan ukuran titik mengindikasikan adanya korelasi positif antara PM10 dan PM2.5, dengan konsentrasi PM2.5 yang cenderung tinggi pada nilai PM10 yang besar. Visualisasi ini menunjukkan variasi polusi yang kompleks dan tidak memiliki pola yang jelas terhadap kecepatan angin.


3.3.3 Statistika Deskriptif dan Visualisasi Data NO2



Gambar 3.3. 3 Statistika NO2

Histogram menunjukkan distribusi NO2 yang merata antara 0 hingga 100, dengan frekuensi tertinggi di sekitar 20 hingga 30. Boxplot memperlihatkan median di sekitar 50, dengan data tersebar merata tanpa outlier signifikan. Scatter plot antara NO2 dan Wind Speed menunjukkan persebaran nilai NO2 yang tidak memiliki pola jelas terhadap kecepatan angin, tetapi PM2.5 tampaknya berkorelasi positif.


3.3.4 Statistika Deskriptif dan Visualisasi Data SO2



Gambar 3.3. 4 Statistika SO2

Distribusi SO2 terlihat merata pada rentang 0 hingga 50, dengan frekuensi tertinggi di sekitar nilai 20. Boxplot menunjukkan median sekitar 25, dengan persebaran data yang simetris. Scatter plot memperlihatkan bahwa SO2 memiliki persebaran yang merata tanpa hubungan yang terlihat dengan Wind Speed, namun PM2.5 cenderung tinggi ketika SO2 meningkat.


3.3.5 Statistika Deskriptif dan Visualisasi Data CO



Gambar 3.3. 5 Statistika CO

Histogram memperlihatkan distribusi CO antara 0 hingga 10 dengan frekuensi yang relatif stabil. Boxplot menunjukkan median sekitar 5, dengan data yang tersebar merata dan simetris. Scatter plot menunjukkan bahwa nilai PM2.5 cenderung meningkat seiring dengan peningkatan CO, meskipun kecepatan angin tidak memberikan pengaruh signifikan.


3.3.6 Statistika Deskriptif dan Visualisasi Data O3



Gambar 3.3. 6 Statistika O3

Histogram memperlihatkan distribusi O3 antara 0 hingga 10 dengan frekuensi yang relatif stabil. Boxplot menunjukkan median sekitar 5, dengan data yang tersebar merata dan simetris. Scatter plot menunjukkan bahwa nilai PM2.5 cenderung meningkat seiring dengan peningkatan CO, meskipun kecepatan angin tidak memberikan pengaruh signifikan.


3.3.7 Statistika Deskriptif dan Visualisasi Data *Temperature*



Gambar 3.3. 7 Statistika Temperature

Histogram temperature menunjukkan distribusi antara -10 hingga 40 derajat, dengan frekuensi tertinggi di sekitar 0 hingga 10. Boxplot menunjukkan median sekitar 15, dengan persebaran data yang luas. Scatter plot antara Temperature dan Wind Speed menunjukkan persebaran merata, tetapi PM2.5 memiliki variasi yang signifikan di berbagai rentang suhu.


3.3.8 Statistika Deskriptif dan Visualisasi Data Humidity



Gambar 3.3. 8 Statistika Humidity

Distribusi kelembaban berkisar antara 0 hingga 100, dengan frekuensi tertinggi di sekitar nilai 50. Boxplot menunjukkan median kelembaban sekitar 60, dengan persebaran yang merata. Scatter plot menunjukkan bahwa kelembaban memiliki hubungan yang tidak signifikan dengan Wind Speed, sementara nilai PM2.5 terlihat cukup beragam.

3.3.9 Statistika Deskriptif dan Visualisasi Data Wind Speed



Gambar 3.3. 9 Statistika Wind Speed

Histogram kecepatan angin menunjukkan distribusi antara 0 hingga 20, dengan puncak frekuensi di sekitar nilai 10 hingga 15. Boxplot memperlihatkan median sekitar 10, dengan persebaran data yang simetris. Scatter plot antara Wind Speed And Humidity tidak menunjukkan pola yang signifikan, sementara nilai PM2.5 tampak bervariasi.

3.4 Pengolahan Data

3.4.1 Normalisasi Data dengan Min Max Scaling

Setelah dilakukan tahap *Data Cleansing* dan Seleksi Data, didapat data dalam numerik yang siap diolah. Namun, pada dataset tersebut masih banyak fitur-fitur dengan range yang jauh berbeda. Oleh karena itu, perlu dilakukan normalisasi data agar tidak terjadi bias saat dilakukan pengolahan data. Kami menormalisasikan dataset kami menggunakan metode *Min Max Scaling*. Untuk dapat menormalisasikan data dengan bahasa pemrograman *python*, *import* pustaka *MinMaxScaler* dari *sklearn.preprocessing*, lalu aplikasikan rumus kode berikut :


```
# Scale data using MinMaxScaler
scaler = MinMaxScaler()
X = scaler.fit_transform(df_features)
df_minmax = pd.DataFrame(data=X, columns=df_features.columns.tolist())
X = MinMaxScaler().fit_transform(df_features)
df_minmax = pd.DataFrame(data=X, columns=df_features.columns.tolist())
```

Sehingga didapat data yang telah dinormalisasi seperti di bawah :

	PM2.5	PM10	NO2	SO2	CO	O3	Temperature	Humidity	Wind Speed
0	0.562201	0.079850	0.998842	0.606638	0.442640	0.138411	0.552505	0.548265	0.680227
1	0.313119	0.460893	0.454096	0.157550	0.335025	0.707406	0.267735	0.639012	0.299176
2	0.864648	0.248892	0.984418	0.182340	0.002030	0.892816	0.705210	0.214079	0.634398
3	0.791808	0.635740	0.062645	0.655808	0.775635	0.150860	0.662325	1.000000	0.368692
4	0.344792	0.140173	0.756370	0.426757	0.192893	0.300876	0.519439	0.892238	0.700824

Gambar 3.4.1. 1 Hasil Normalisasi

Apabila data yang telah dinormalisasikan tersebut divisualisasikan, maka akan terlihat diagram *scatterplot* sebagai berikut :



Gambar 3.4.1. 2 Scatterplot setelah dinormalisasi


3.4.2 Mencari Cluster dengan Elbow Method

Untuk mengaplikasikan *Elbow Method*, kita perlu meng-install package *kneed* dan meng-import beberapa kelas, yaitu *KneeLocator* dari *kneed* dan *KMeans* dari *sklearn.cluster*. Lalu, dapat langsung dimasukkan rumus untuk mencari berapa *cluster* yang diperlukan dengan kode berikut :

```
kmeans_kwargs = {
    "init": "random",
    "n_init": 10,
    "max_iter": 300,
    "random_state": 42,
}

# A list holds the SSE values for each k
sse = []
for k in range(1, 21):
    kmeans = KMeans(n_clusters=k, **kmeans_kwargs)
    kmeans.fit(X)
    sse.append(kmeans.inertia_)
plt.plot(range(1, 21), sse)
plt.xticks(range(1, 21))
plt.xlabel("Number of Clusters")
plt.ylabel("SSE")
plt.show()
```

Dari kode tersebut, didapat hasil seperti di bawah :



Gambar 3.4.2.1 Hasil Elbow Method

Untuk mencari berapa *cluster* yang paling optimal dalam pengolahan data ini, dapat digunakan rumus berikut :

```
kl = KneeLocator(range(1, 21), sse, curve="convex",  
direction="decreasing")  
  
kl.elbow
```


Dari aplikasi rumus tersebut, didapat **k=7** lah yang paling optimal.

3.4.3 Mencari Cluster dengan Silhouette Coefficient

Dalam mengaplikasikan *Silhouette Coefficient*, terlebih dulu harus meng-import *silhouette_score* dari *sklearn.metrics* untuk memanggil kelas yang akan diaplikasikan. Setelah itu, kita bisa langsung memasukkan rumus sebagai berikut :

```
# A list holds the silhouette coefficients for each k  
silhouette_coefficients = []  
  
# start at 2 clusters for silhouette coefficient  
for k in range(2, 21):  
    kmeans = KMeans(n_clusters=k, **kmeans_kwargs)  
    kmeans.fit(X)  
    score = silhouette_score(X, kmeans.labels_)  
    silhouette_coefficients.append(score)  
  
plt.plot(range(2, 21), silhouette_coefficients)  
plt.xticks(range(2, 21))  
plt.xlabel("Number of Clusters")  
plt.ylabel("Silhouette Coefficient")  
plt.show()
```

Dari rumus tersebut, akan tampil hasil seperti di bawah :




Gambar 3.4.3 1 Hasil Silhouette Coefficient

Hasil dari Silhouette Coefficient menunjukkan jumlah klaster (K=19)

3.4.4 Mencari *Cluster* dengan *KMeans*

Mencari *KMeans* dapat langsung dilakukan dengan mengaplikasikan rumus sebagaimana tertera di bawah :

```
kmeans = KMeans(  
    init="random",  
    n_clusters=7,  
    n_init=10,  
    max_iter=300,  
    random_state=42  
)  
  
kmeans.fit(X)
```



Gambar 3.4.4 1 KMeans

Kode tersebut berfungsi untuk melatih data yang diolah untuk mencari *centroid*-nya sesuai dengan jumlah *cluster* yang diinginkan. Selanjutnya, kita dapat menghitung nilai SSE terendah, lokasi *centroid*, dan banyak iterasi yang perlu untuk dilakukan, menggunakan rumus :


```
# The lowest SSE value  
print(kmeans.inertia_)  
  
# Final locations of the centroid  
print(kmeans.cluster_centers_)  
  
# The number of iterations required to converge  
print(kmeans.n_iter_)
```

Sehingga, didapat hasil berikut :

```
534.0645018343782  
[[0.2520732  0.40601142  0.34665036  0.63489712  0.6146602  0.37513758  
  0.32010738  0.51710642  0.30731128]  
 [0.49976215  0.67270072  0.72158478  0.5983203  0.39128423  0.54779703  
  0.22913446  0.45991826  0.72101487]  
 [0.69465808  0.44423417  0.25792784  0.46926653  0.60077675  0.44903499  
  0.44454681  0.18959657  0.61808901]  
 [0.74441481  0.40661607  0.75285867  0.47299007  0.62921238  0.55396956  
  0.50507337  0.48444137  0.29651507]  
 [0.70354203  0.69316023  0.27041482  0.45541979  0.60846294  0.53987172  
  0.50043287  0.77320819  0.58259938]  
 [0.28628261  0.46279609  0.63869681  0.54867869  0.43849692  0.40466634  
  0.77759411  0.54749561  0.70412776]  
 [0.33641724  0.55433781  0.41005475  0.27426025  0.30417694  0.75531136  
  0.60376038  0.50037811  0.34065396]]  
32
```

Dengan nilai SSE terendah 534.0645018343782, serta melalui 32 kali iterasi.

3.4.5 Visualisasi *Clustering Data*



Pada visualisasi data yang dihasilkan, dapat dilihat terdapat 7 cluster data yang terpisah dengan warna yang berbeda. Dimana, di setiap warna klaster mewakili kelompok data dengan karakteristik tertentu. Hubungan antar klaster dengan PC1 dan PC2 dapat ditunjukkan dari :

1. *Cluster 0* diwakilkan oleh warna **ungu** berada disekitar nilai pc1 negatif dan pc2 bernilai negatif dan positif. Pada *Cluster 0* terdapat sebanyak **134** data.
2. *Cluster 1* diwakilkan oleh warna **nila** berada disekitar nilai pc1 positif dan pc2 positif. Pada *Cluster 1* terdapat sebanyak **147** data.
3. *Cluster 2* diwakilkan oleh warna **biru** berada disekitar nilai pc1 negatif, dan pc2 positif. Pada *Cluster 2* terdapat sebanyak **149** data.
4. *Cluster 3* diwakilkan oleh warna **hijau tosca** berada disekitar nilai pc1 positif dan negatif, serta pc2 juga positif dan negatif. Pada *Cluster 3* terdapat sebanyak **155** data.
5. *Cluster 4* diwakilkan oleh warna **hijau** berada disekitar nilai pc1 negatif dan pc2 positif. Pada *Cluster 4* terdapat sebanyak **125** data.
6. *Cluster 5* diwakilkan oleh warna **lime** berada disekitar nilai pc1 positif dan pc2 bernilai positif dan negatif. Pada *Cluster 5* terdapat sebanyak **149** data.
7. *Cluster 6* diwakilkan oleh warna **kuning** berada disekitar nilai pc1 positif dan negatif serta pc2 positif dan negatif. Pada *Cluster 6* terdapat sebanyak **140** data.

3.4.6 Cluster Profiling & Analysis

```
# Add the cluster labels to the original DataFrame
df_clustered = data_filtered.copy()
df_clustered['Cluster'] = membership

# Analyze each cluster
for cluster_num in range(7):
    cluster_data = df_clustered[df_clustered['Cluster'] == cluster_num]
    print(f"\nCluster {cluster_num}:")
    print(cluster_data.describe())

    # Check the average pollution levels for the cluster
    pollutants = ['PM2.5', 'PM10', 'NO2', 'SO2', 'CO', 'O3']
    avg_pollution = cluster_data[pollutants].mean()
    print("\nAverage Pollution Levels:")
    print(avg_pollution)

    # Analyze the relationship between temperature/windspeed and
    # pollutants within the cluster
    print("\nCorrelation between Temperature/Windspeed/Humidity and
    Pollutants:")
    correlation_matrix = cluster_data[['Temperature', 'Humidity', 'Wind
    Speed'] + pollutants].corr()
    print(correlation_matrix)

    # Visualization for each cluster
    plt.figure(figsize=(10, 6))
    sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm',
    fmt=".2f")
    plt.title(f"Correlation Heatmap for Cluster {cluster_num}")
    plt.show()
```


Di mana dari hasil kode tersebut *cluster-cluster* dapat diinterpretasikan sebagai berikut :

Cluster	PM2.5	PM10	NO2	SO2	CO	Suhu	Kelembapan	Windspeed
0	41.82	86.99	37.93	32.00	6.15	6.07	56.54	6.52
1	77.56	137.52	73.54	30.22	3.95	1.53	64.10	14.55
2	105.68	94.23	29.50	23.92	3.92	12.28	27.10	12.55
3	112.86	87.10	76.52	24.10	6.29	15.30	53.61	6.30
4	106.96	141.40	30.69	23.24	6.09	15.07	79.57	11.86
5	46.75	97.75	65.67	27.80	4.41	28.90	59.28	14.22
6	53.99	115.09	43.95	14.40	3.09	20.22	55.04	7.16

Tabel 3.4.5 Hasil Clustering 1

Berdasarkan hasil dari clustering diatas maka dapat diinterpretasikan bahwa

- Cluster 0: Polusi rendah hingga sedang dengan suhu rendah.
- Cluster 1: Polusi sedang-tinggi dengan suhu sangat rendah dan angin kencang.
- Cluster 2: PM2.5 tinggi, kelembaban rendah, dan angin kencang.
- Cluster 3: Polusi tinggi, suhu hangat, dan angin rendah.
- Cluster 4: PM2.5 dan PM10 tinggi dengan kelembaban tertinggi.
- Cluster 5: Polusi rendah-sedang, suhu tinggi, dan angin kuat.
- Cluster 6: Polusi sedang dengan suhu cukup tinggi dan angin moderat.

3.4.6 Principal Component Analysis

Principal Component Analysis (PCA) adalah metode statistik yang digunakan untuk mereduksi dimensi data dengan tetap mempertahankan sebanyak mungkin informasi dari data asli. Dengan menggunakan PCA, data dapat direpresentasikan dalam komponen utama (Principal Components) yang merupakan kombinasi linear dari fitur asli. Cara kerja PCA dapat dilihat sebagai berikut:

```
pca_features = pd.DataFrame(x_pca, columns=['pc'+str(i) for i in
range(1, x_pca.shape[1]+1)])
pca_features
```

Dari kode di atas, akan muncul hasil seperti di bawah :

	pc1	pc2	pc3	pc4	pc5	pc6	pc7	pc8	pc9
0	0.101970	0.367834	0.459225	0.215321	-0.066374	0.277803	-0.276398	-0.075741	-0.281809
1	-0.276901	-0.296875	-0.055473	-0.075397	0.138937	-0.214574	-0.077367	-0.193858	-0.231176
2	-0.352116	0.043993	0.550623	-0.664983	0.027168	0.230081	-0.358410	0.137946	-0.074744
3	0.257026	-0.031011	-0.344450	0.469878	0.255150	0.115380	0.279650	0.487774	-0.161291
4	-0.267967	0.273591	0.226572	0.278404	0.000509	-0.039059	-0.330899	0.030845	-0.447973
...	...	...	...	...	...	...	...	...	...
994	-0.507107	0.186042	-0.168130	-0.150882	-0.262418	0.152777	-0.153947	0.132009	0.385946
995	0.235064	-0.087320	0.479353	0.168244	0.169942	0.564230	-0.298672	0.340461	0.250227
996	0.428570	0.116822	-0.314305	0.129191	0.141540	-0.067682	-0.213980	-0.295610	-0.138589
997	0.538126	-0.472184	0.333496	0.217536	0.026428	0.120408	0.209934	0.322058	0.244843
998	0.184360	-0.110541	-0.250078	-0.295281	-0.299040	0.433627	-0.604354	0.052631	0.372916

999 rows × 9 columns

Gambar 3.4.6. 1 PCA Features

Kolom pc1, pc2, pc3, pc4, pc5, pc6, pc7, pc8, pc9 diatas mewakili 9 principal components yang dihasilkan dari PCA. PCA bertujuan mereduksi dimensi data asli menjadi representasi baru yang lebih ringkas, sambil mempertahankan sebanyak mungkin informasi varians dari data asli.

Nilai-nilai dalam tiap tabel di atas menunjukkan koordinat data dalam sumbu baru, yaitu *Principal Components*. Nilai ini merepresentasikan seberapa besar data tersebut dipengaruhi oleh komponen terkait.

```
df_minmax_vars = df_minmax.var()
print(df_minmax_vars)
```

Dari kode di atas, akan muncul hasil seperti di bawah :

```
PM2.5      0.084514
PM10       0.082857
NO2        0.084779
SO2        0.083019
CO         0.083392
O3         0.080112
Temperature 0.081269
Humidity    0.084864
Wind Speed  0.085591
dtype: float64
```

Gambar 3.4.6. 2 Varians

Kolom di atas menunjukkan varians untuk setiap fitur (kolom dataset) setelah normalisasi Min-Max Scaling. Varians menjelaskan penyebaran data dalam kolom. Nilai varians yang besar berarti datanya lebih menyebar, sementara nilai kecil berarti datanya lebih rapat. Sehingga dapat ditarik kesimpulan bahwa variabel **Humidity dan Wind Speed memiliki penyebaran data paling besar** setelah normalisasi. Sedangkan variabel **O3 memiliki penyebaran data paling kecil**.

```
df_minmax_varsum = sum(df_minmax_vars)
-np.sort(-np.array([a/df_minmax_varsum for a in df_minmax_vars]))
```

Dari kode di atas, akan muncul hasil seperti di bawah :

```
array([0.11406121, 0.1130924 , 0.11297902, 0.11262501, 0.11113098,
       0.11063391, 0.11041696, 0.10830106, 0.10675946])
```

Gambar 3.4.6. 3 Kontribusi Relatif

Array ini menunjukkan kontribusi relatif dari masing-masing kolom terhadap total varians dataset. Setiap nilai dihitung dengan membagi varians kolom terhadap total varians dataset:

Kontribusi Relatif Kolom = Varians Kolom / Total Varians

Nilai yang lebih tinggi berarti fitur tersebut memberikan kontribusi lebih besar terhadap total varians dataset. Fitur seperti Wind Speed dan Humidity memberikan kontribusi terbesar terhadap total varians dataset. Sehingga dapat ditarik kesimpulan bahwa variabel **Humidity dan Wind Speed memiliki kontribusi terbesar terhadap total varians dataset**. Sedangkan variabel **O3 memiliki kontribusi terkecil terhadap total varians dataset**.

```
X = data_filtered[['Temperature', 'Humidity', 'Wind Speed']]
Y = data_filtered[['PM2.5', 'PM10', 'NO2', 'SO2', 'CO', 'O3']]
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score
# Loop for every pollutants (Y.columns)
for pollutant in Y.columns:
    # Regression model for initialization
    model = LinearRegression()

    # fit model using temperature
    model.fit(X, Y[pollutant])
```

```

# Prediction for X value
predictions = model.predict(X)

# Calculate the R2 Score
r2 = r2_score(Y[pollutant], predictions)

# save the results
results[pollutant] = {
    'R2 Score': r2,
    'Coefficients': model.coef_,
    'Intercept': model.intercept_
}

# format the results into a DataFrame
results_df = pd.DataFrame({
    'Pollutant': results.keys(),
    'R2 Score': [res['R2 Score'] for res in results.values()],
    'Temperature Coefficient': [res['Coefficients'][0] for res in
results.values()],
    'Humidity Coefficient': [res['Coefficients'][1] for res in
results.values()],
    'Wind Speed Coefficient': [res['Coefficients'][1] for res in
results.values()],
    'Intercept': [res['Intercept'] for res in results.values()]
})

```

Dari kode di atas, akan muncul hasil seperti di bawah :

	Pollutant	R2 Score	Temperature Coefficient	Humidity Coefficient	Wind Speed Coefficient	Intercept
0	PM2.5	0.007284	-0.217175	-0.066251	-0.066251	84.784116
1	PM10	0.004755	0.006346	0.086773	0.086773	97.573885
2	NO2	0.001990	0.046462	0.035361	0.035361	48.561692
3	SO2	0.001607	-0.037416	0.001297	0.001297	25.263359
4	CO	0.003767	-0.010898	0.002069	0.002069	5.301437
5	O3	0.005217	0.011066	0.052691	0.052691	111.837081

Gambar 3.4.6. 4 Hasil Penggunaan Regresi Linear

Penggunaan regresi linear dalam kode bertujuan untuk mengevaluasi kontribusi masing-masing fitur (variabel independen seperti Temperature, Humidity, dan Wind Speed) terhadap variabel target (seperti PM2.5, PM10, NO2, dll). Regresi linear membantu mengukur sejauh mana variasi dalam fitur dapat menjelaskan variasi dalam target menggunakan metrik seperti koefisien regresi atau nilai R^2 . Fitur yang memiliki kontribusi signifikan akan menunjukkan kemampuan prediktif yang lebih kuat terhadap variabel target. Dalam konteks ini, regresi linear dapat digunakan sebagai analisis awal untuk memahami variabilitas data sebelum menerapkan PCA dan Clustering on Principal Components.

Hubungannya dengan PCA (Principal Component Analysis) adalah bahwa PCA bertujuan untuk mereduksi dimensi data dengan mempertahankan sebanyak mungkin varians dalam dataset. Fitur-fitur yang memiliki kontribusi besar terhadap varians total (ditemukan melalui regresi linear) kemungkinan akan menjadi komponen utama dalam PCA. Dengan demikian, regresi linear dapat membantu memilih fitur penting yang lebih berpengaruh, sehingga proses PCA dapat menjadi lebih efisien.

Kinerja model diukur menggunakan skor R^2 yang menunjukkan seberapa baik fitur mampu menjelaskan variasi target. Koefisien regresi untuk setiap fitur (suhu, kelembapan, dan kecepatan angin) serta intercept-nya juga disimpan. Hasil ini kemudian diformat ke dalam bentuk Data Frame untuk mempermudah pembacaan, di mana setiap polutan memiliki skor R^2 , koefisien untuk masing-masing fitur, dan intercept.

- **R^2 Score** : Mengukur seberapa baik model menjelaskan variansi data polutan berdasarkan suhu, kelembapan, dan kecepatan angin.
- **Temperature Coefficient** : Mengukur seberapa besar pengaruh Temperature terhadap tingkat polutan
- **Humidity Coefficient** : Mengukur pengaruh Humidity terhadap tingkat polutan.
- **Wind Speed Coefficient** : Mengukur pengaruh Wind Speed terhadap tingkat polutan.
- **Intercept** : Nilai dasar tingkat polutan ketika semua faktor (Temperature, Humidity, Wind Speed) bernilai nol.

3.4.7 Clustering on Principal Components

Clustering pada komponen utama dilakukan untuk mengevaluasi bagaimana pengurangan dimensi menggunakan Principal Component Analysis (PCA) memengaruhi hasil clustering. PCA digunakan untuk mereduksi kompleksitas data dengan mempertahankan variasi terbesar dalam beberapa komponen utama. Proses ini membandingkan hasil clustering dengan menggunakan seluruh komponen PCA, satu komponen pertama, dua komponen pertama, dan tiga komponen pertama.

```
# Code for All PCA Features
kmeans_pca_all = KMeans(
    init="random",
    n_clusters=7,
    n_init=10,
    max_iter=300,
    random_state=42
)
print(kmeans_pca_all.inertia_)
print(kmeans_pca_all.cluster_centers_)
print(kmeans_pca_all.n_iter_)

#mencari V-measure
from sklearn.metrics import v_measure_score
v_measure_score(kmeans.labels_, kmeans_pca_all.labels_)

#use the code for first, first two, and first three
kmeans_pca_all = KMeans(
    init="random",
    n_clusters=7,
    n_init=10,
    max_iter=300,
    random_state=42
)
print(kmeans_pca_first.inertia_)
print(kmeans_pca_first.cluster_centers_)
print(kmeans_pca_first.n_iter_)
v_measure_score(kmeans.labels_, kmeans_pca_first.labels_)
```

Tabel berikut menyajikan ringkasan hasil clustering menggunakan seluruh komponen PCA, satu komponen pertama, dua komponen pertama, dan tiga komponen pertama. Perbandingan ini menunjukkan bagaimana variasi jumlah komponen PCA mempengaruhi kualitas clustering.

Metode	SSE	Jumlah Iterasi	Lokasi Centroid	V-Measure	Interpretasi
PCA All Features	534.06	32	Seluruh komponen PCA	1.0	Informasi penuh dari data dipertahankan, hasil clustering identik dengan data asli.
First PCA(1 Komp.)	3.71	20	Satu dimensi (komponen pertama)	0.1711	Data sangat disederhanakan, kehilangan banyak informasi, kualitas clustering rendah.
First Two PCA	38.43	27	Dua dimensi (komponen pertama & kedua)	0.2401	Informasi bertambah, kualitas clustering meningkat dibandingkan satu komponen.
First Three PCA	97.59	25	Tiga dimensi (komponen pertama, kedua, & ketiga)	0.2629	Keseimbangan antara kompleksitas dan kualitas clustering dengan hasil yang lebih representatif.

Tabel 3.4.7. 1 Hasil Perbandingan Clustering PCA

Hasil analisis menunjukkan bahwa semua fitur PCA menghasilkan clustering yang paling identik dengan data asli, dengan nilai V-measure 1.0. Namun, penggunaan komponen pertama hingga tiga komponen pertama memberikan hasil yang lebih sederhana dan lebih cepat konvergen tetapi dengan penurunan kualitas clustering. Nilai V-measure bertambah seiring dengan penambahan jumlah komponen PCA hingga 5, namun tidak memberikan penambahan nilai signifikan dan hingga first five pca tidak mencapai 0,5

Kami memilih First Two PCA karena memberikan keseimbangan optimal antara efisiensi, kualitas clustering, dan kemudahan interpretasi. Meskipun First Three PCA memiliki kualitas clustering sedikit lebih tinggi, peningkatan tersebut tidak signifikan jika dibandingkan dengan biaya tambahan berupa kompleksitas dimensi. Dengan hanya dua komponen, kita sudah mendapatkan hasil yang representatif dan lebih mudah dianalisis.

3.4.8 Identifikasi Polusi Tertinggi

Tahap ini bertujuan untuk menghitung total polusi dari semua parameter polutan yang ada dalam dataset. Proses dimulai dengan menjumlahkan nilai konsentrasi polutan **PM2.5**, **PM10**, **NO2**, **SO2**, **CO**, dan **O3** untuk setiap baris data. Hasil penjumlahan ini disimpan dalam kolom **Total Pollution**. Selanjutnya, ditentukan baris yang memiliki nilai total polusi tertinggi dengan menggunakan indeks maksimum dari kolom tersebut.

```
# Calculate the total for each row
pollutants = ['PM2.5_x', 'PM10_x', 'NO2_x', 'SO2_x', 'CO_x', 'O3_x']
df['Total_Pollution'] = df[pollutants].sum(axis=1)

#Identify the row with the maximum total pollution
max_pollution_row = df.loc[df['Total_Pollution'].idxmax()]

return max_pollution_row['Country'], max_pollution_row['City'],
max_pollution_row['Total_Pollution']
```

Berdasarkan hasil analisis menggunakan kode di atas, diperoleh bahwa negara dengan total polusi tertinggi adalah **Germany, Berlin dengan nilai total polusi 612,83**. Informasi ini menunjukkan bahwa konsentrasi gabungan dari seluruh polutan di salah satu kota di Jerman mencapai nilai tertinggi dalam dataset, sehingga dapat menjadi perhatian utama dalam upaya mitigasi polusi udara.

3.4.9 Identifikasi Polutan di Tiap Cluster

Tahap ini dilakukan untuk mengidentifikasi polutan dengan rata-rata tertinggi pada masing-masing cluster. Proses dimulai dengan menghitung nilai rata-rata untuk setiap polutan dalam cluster, kemudian dipilih polutan dengan nilai rata-rata tertinggi. Selanjutnya, ditentukan baris data yang memiliki nilai maksimum dari polutan tersebut untuk mendapatkan informasi mengenai negara dan kota tempat polusi tertinggi terjadi.

```
# Find the pollutant with the highest average in the cluster
cluster_0_data = df_clustered[df_clustered['Cluster'] == 0]
```



```

pollutants = ['PM2.5_x', 'PM10_x', 'NO2_x', 'SO2_x', 'CO_x', 'O3_x']
avg_pollution_cluster_0 = cluster_0_data[pollutants].mean()
highest_pollutant = avg_pollution_cluster_0.idxmax()
max_pollutant_value = avg_pollution_cluster_0.max()

# Identify the row with the highest value of the pollutant
max_pollutant_row =
cluster_0_data.loc[cluster_0_data[highest_pollutant] ==
cluster_0_data[highest_pollutant].max()]

print(f"The highest average pollutant in cluster 0 is
{highest_pollutant} with an average value of
{max_pollutant_value:.2f}")

# Print
if not max_pollutant_row.empty:
    print(f"Country and city with the maximum {highest_pollutant}
({cluster_0_data[highest_pollutant].max():.2f}) in cluster 0:")
    for index, row in max_pollutant_row.iterrows():
        print(f"Country: {row['Country']}, City: {row['City']}")
else:
    print("No data found for the maximum pollutant in cluster 0.")

```

Berdasarkan hasil analisis menggunakan kode di atas, diperoleh identifikasi polutan tertinggi pada masing-masing cluster sebagai berikut:

- Cluster 0: Polutan dengan rata-rata tertinggi adalah PM10 dengan nilai 193.67, yang tercatat di Johannesburg, South Africa.
- Cluster 1: Polutan dengan rata-rata tertinggi adalah PM10 dengan nilai 199.54, yang tercatat di Johannesburg, South Africa.
- Cluster 2: Polutan dengan rata-rata tertinggi adalah PM2.5 dengan nilai 149.74, yang tercatat di Los Angeles, USA.
- Cluster 3: Polutan dengan rata-rata tertinggi adalah O3 dengan nilai 196.21, yang tercatat di Toronto, Canada.
- Cluster 4: Polutan dengan rata-rata tertinggi adalah PM10 dengan nilai 198.93, yang tercatat di Rio de Janeiro, Brazil.
- Cluster 5: Polutan dengan rata-rata tertinggi adalah PM10 dengan nilai 199.28, yang tercatat di Paris, France.
- Cluster 6: Polutan dengan rata-rata tertinggi adalah O3 dengan nilai 199.32, yang tercatat di Seoul, South Korea.

Hasil ini menunjukkan bahwa polutan PM10 dan O3 mendominasi sebagai polutan tertinggi dalam beberapa cluster, dengan konsentrasi tertinggi terdeteksi di kota-kota besar seperti Johannesburg, Los Angeles, Toronto, Rio de Janeiro, Paris, dan Seoul.

BAB 4

KESIMPULAN

Proses analisis data dimulai dengan Data Cleaning untuk memastikan kualitas data, menghapus data yang tidak valid, kosong, atau tidak relevan. Setelah itu, atribut yang paling relevan dipilih, dan data dinormalisasi untuk mengurangi variabilitas yang ekstrem (outlier). Teknik Principal Component Analysis (PCA) digunakan untuk mengurangi dimensi data, diikuti oleh K-Means Clustering untuk mengelompokkan data berdasarkan kesamaan fitur.

Hasil analisis menunjukkan bahwa faktor cuaca seperti kecepatan angin (wind speed), suhu (temperature), dan kelembaban udara (humidity) memiliki pengaruh yang sangat kecil terhadap variansi konsentrasi polutan utama (PM10, PM2.5, NO2, CO, dan O3). Hal ini ditunjukkan oleh nilai R^2 yang rendah.

Berdasarkan analisis juga diperoleh bahwa setiap cluster memiliki dominasi polutan yang berbeda, mencerminkan variasi aktivitas manusia, sumber emisi lokal, dan faktor geografis. PM10 menjadi polutan dominan di wilayah seperti Johannesburg, Rio de Janeiro, dan Paris, sementara PM2.5 mencatatkan rata-rata tertinggi di Los Angeles, dan O3 mendominasi di Toronto dan Seoul. Dan secara keseluruhan, negara dan kota dengan tingkat polusi tertinggi adalah Jerman (Berlin) dengan total konsentrasi polutan sebesar 612.83.

DAFTAR PUSTAKA

Apa itu Analisis Komponen Utama (PCA)? (n.d.). IBM. Diakses pada 16 Desember 2024, dari <https://www.ibm.com/id-id/topics/principal-component-analysis>

Apa itu K Means Clustering? Pengertian dan Contoh 2024. (n.d.). RevoU. Diakses pada 16 Desember 2024, dari <https://revou.co/kosakata/k-means-clustering>

Clustering Algoritma (K-Means) – School of Information Systems. (2022, 31 Januari). School of Information Systems. Diakses pada 16 Desember 2024, dari <https://sis.binus.ac.id/2022/01/31/clustering-algoritma-k-means/>

4 Cara untuk Menghitung Kovarian. (n.d.). wikiHow. Diakses pada 16 Desember 2024, dari <https://id.wikihow.com/Menghitung-Kovarian>

Jain, S. (2024, 3 Oktober). **Eigen Decomposition of a Matrix.** GeeksforGeeks. Diakses pada 16 Desember 2024, dari <https://www.geeksforgeeks.org/eigen-decomposition-of-a-matrix/>

Principal Component Analysis: Pengertian dan Cara Kerjanya. (2022, 29 Maret). Algoritma Data Science. Diakses pada 16 Desember 2024, dari <https://algoritma.blog/principal-component-analysis-2022/>
Risyad, S. A. (2023, 3 Juni).

Data Cleaning: Arti, Manfaat, dan Cara Melakukannya. dibimbing. Diakses pada 11 Juni 2024, dari <https://dibimbing.id/blog/detail/data-cleaning-arti-manfaat-dan-cara-melakukannya>