

Analisis Cluster *Air Quality* di Berbagai Negara tahun 2023



Anggota Kelompok :

1. Nicholas Evan Sitanggang - 5026231146
2. Kayla Putri Maharani - 5026231158
3. Tahiyyah Mufhimah - 5026231170
4. Sahilah Amru Yumnatusta - 5026231182

Sumber Data

Analisis Kluster pada Global Air Quality Data

- Dataset ini kami dapatkan dari website Kaggle
- Dengan link sebagai berikut :
<https://www.kaggle.com/datasets/waqi786/global-air-quality-dataset>



Latar Belakang

Kualitas udara merupakan faktor penting bagi kesehatan lingkungan dan manusia. Dalam beberapa dekade terakhir, urbanisasi, aktivitas industri, dan penggunaan kendaraan bermotor di kota besar telah meningkatkan polusi udara, yang bisa menyebabkan masalah kesehatan seperti gangguan pernapasan dan kardiovaskular, serta merusak ekosistem. Oleh karena itu, penting untuk memiliki data yang akurat dan komprehensif untuk memahami pola polusi udara dan mengevaluasi dampaknya guna mengembangkan mitigasinya.

Dataset *Global Air Quality Data* mencakup informasi kualitas udara dari kota besar dunia, termasuk konsentrasi polutan (PM2.5, PM10, NO2, SO2, CO, O3) dan data meteorologi (suhu, kelembaban, kecepatan angin). Dengan 1000 catatan, dataset ini bertujuan untuk menganalisis tren kualitas udara secara global.

Melalui analisis dataset ini, diharapkan tercipta wawasan mendalam untuk mendukung inisiatif lingkungan yang lebih bersih dan sehat bagi generasi kini dan mendatang.



Rumusan Masalah

- ✓ Apakah kecepatan angin (wind speed), suhu (temperature), dan kelembapan udara (humidity) mempengaruhi konsentrasi atau nilai dari polutan di udara?
- ✓ Bagaimana distribusi rata-rata polutan utama (PM10, PM2.5, NO2, CO, dan O3) di setiap cluster
- ✓ Negara mana yang tercatat memiliki tingkat polusi udara tertinggi di dunia, berdasarkan data konsentrasi polutan utama?

Tujuan

- ✓ Untuk mengetahui apakah kecepatan angin (wind speed), suhu (temperature), dan kelembapan udara (humidity) mempengaruhi konsentrasi atau nilai dari polutan udara, seperti PM10, PM2.5, NO2, dan CO, O3.
- ✓ Untuk menganalisis rata-rata konsentrasi polutan utama (PM10, PM2.5, NO2, CO, dan O3) di setiap cluster untuk memahami tingkat polusi udara.
- ✓ Untuk mengidentifikasi negara yang memiliki tingkat polusi udara tertinggi di dunia, berdasarkan data konsentrasi polutan utama seperti PM10, PM2.5, NO2, CO, dan O3.

Metodologi

7

◆ Data Cleaning

Data cleaning adalah proses identifikasi dan koreksi kesalahan, ketidakakuratan, dan anomali dalam dataset, dan juga menghapus data yang tidak memiliki nilai.

Tujuannya adalah untuk memastikan bahwa data yang digunakan untuk analisis atau pemrosesan benar, akurat, dan dapat diandalkan.

◆ K-Means Clustering

K-Means Clustering adalah suatu metode penganalisaan data atau metode Data Mining yang melakukan proses pemodelan unsupervised learning dan menggunakan metode yang mengelompokkan data berbagai partisi.

Tujuannya adalah untuk meminimalisasikan fungsi objective yang telah di set dalam proses clustering.

◆ PCA

Principal Component Analysis (PCA) adalah teknik yang digunakan untuk menyederhanakan suatu data, dengan cara mentransormasi linear sehingga terbentuk system koordinat baru dengan variansi maksimum.

Tujuannya adalah untuk menangani masalah multikolinearitas dengan mereduksi jumlah variabelnya.



Data Cleaning

Code

```
df.isnull().any(axis=1).sum()  
df.isnull().any(axis=0)
```

- ◆ Setelah memeriksa keberadaan nilai null, dapat dipastikan bahwa dataset ini tidak memiliki data yang kosong, sehingga tidak ada baris yang perlu dihapus.

Output

	0
City	False
Country	False
Date	False
PM2.5	False
PM10	False
NO2	False
SO2	False
CO	False
O3	False
Temperature	False
Humidity	False
Wind Speed	False
dtype: bool	


Standarisasi Data

```
# Scale data using MinMaxScaler
scaler = MinMaxScaler()
X = scaler.fit_transform(df_features)
df_minmax = pd.DataFrame(data=X, columns=df_features.columns.tolist())
X = MinMaxScaler().fit_transform(df_features)
df_minmax = pd.DataFrame(data = X, columns = df_features.columns.tolist())
df_minmax.head()
```

Hasil dari standarisasi data menggunakan MInMax Scaler :


	PM2.5	PM10	N02	S02	CO	O3	Temperature	Humidity	Wind Speed
0	0.562201	0.079850	0.998842	0.606638	0.442640	0.138411	0.552505	0.548265	0.680227
1	0.313119	0.460893	0.454096	0.157550	0.335025	0.707406	0.267735	0.639012	0.299176
2	0.864648	0.248892	0.984418	0.182340	0.002030	0.892816	0.705210	0.214079	0.634398
3	0.791808	0.635740	0.062645	0.655808	0.775635	0.150860	0.662325	1.000000	0.368692
4	0.344792	0.140173	0.756370	0.426757	0.192893	0.300876	0.519439	0.892238	0.700824

Visualisasi Data




Hasil visualisasi dari standarisasi data menggunakan MInMax Scaler

Elbow Method and Silhouette Coefficient



Hasil dari Elbow Method
menunjukkan jumlah kluster (K=7)



Hasil dari Silhoutte Coefficient
menunjukkan jumlah kluster
(K=19)

K-Means Clustering

K-Means Clustering

```
KMeans
```

```
KMeans(init='random', n_clusters=7, n_init=10, random_state=42)
```

```
kmeans = KMeans(
    init="random",
    n_clusters=7,
    n_init=10,
    max_iter=300,
    random_state=42
)
```

```
# The lowest SSE value
print(kmeans.inertia_)
```

```
# Final locations of the centroid
print(kmeans.cluster_centers_)
```

```
# The number of iterations required to converge
print(kmeans.n_iter_)
```

```
534.0645018343782
```

```
[[0.2520732  0.40601142 0.34665036 0.63489712 0.6146602  0.37513758
  0.32010738 0.51710642 0.30731128]
 [0.49976215 0.67270072 0.72158478 0.5983203  0.39128423 0.54779703
  0.22913446 0.45991826 0.72101487]
 [0.69465808 0.44423417 0.25792784 0.46926653 0.60077675 0.44903499
  0.44454681 0.18959657 0.61808901]
 [0.74441481 0.40661607 0.75285867 0.47299007 0.62921238 0.55396956
  0.50507337 0.48444137 0.29651507]
 [0.70354203 0.69316023 0.27041482 0.45541979 0.60846294 0.53987172
  0.50043287 0.77320819 0.58259938]
 [0.28628261 0.46279609 0.63869681 0.54867869 0.43849692 0.40466634
  0.77759411 0.54749561 0.70412776]
 [0.33641724 0.55433781 0.41005475 0.27426025 0.30417694 0.75531136
  0.60376038 0.50037811 0.34065396]]
```

```
32
```


Hasil Clustering

```
import pandas as pd

# Count data points in each cluster
cluster_counts = pd.Series(membership).value_counts()

# Print the counts for each cluster
print("Number of data points in each cluster:")
print(cluster_counts)
```

Number of data points in each cluster:

3	155
5	149
2	149
1	147
6	140
0	134
4	125

Name: count, dtype: int64



Hasil Clustering


```
pc_cluster['Cluster'] = membership
pc_cluster
```

	pc1	pc2	pc3	pc4	pc5	pc6	pc7	pc8	pc9	Cluster
0	0.101970	0.367834	0.459225	0.215321	-0.066374	0.277803	-0.276398	-0.075741	-0.281809	5
1	-0.276901	-0.296875	-0.055473	-0.075397	0.138937	-0.214574	-0.077367	-0.193858	-0.231176	6
2	-0.352116	0.043993	0.550623	-0.664983	0.027168	0.230081	-0.358410	0.137946	-0.074744	3
3	0.257026	-0.031011	-0.344450	0.469878	0.255150	0.115380	0.279650	0.487774	-0.161291	4
4	-0.267967	0.273591	0.226572	0.278404	0.000509	-0.039059	-0.330899	0.030845	-0.447973	5
...	...	...	...	...	...	...	...	...	...	...
994	-0.507107	0.186042	-0.168130	-0.150882	-0.262418	0.152777	-0.153947	0.132009	0.385946	5
995	0.235064	-0.087320	0.479353	0.168244	0.169942	0.564230	-0.298672	0.340461	0.250227	3
996	0.428570	0.116822	-0.314305	0.129191	0.141540	-0.067682	-0.213980	-0.295610	-0.138589	0
997	0.538126	-0.472184	0.333496	0.217536	0.026428	0.120408	0.209934	0.322058	0.244843	3
998	0.184360	-0.110541	-0.250078	-0.295281	-0.299040	0.433627	-0.604354	0.052631	0.372916	2

Clustering dilakukan berdasarkan kesamaan karakteristik data kualitas udara dan kondisi lingkungan



Hasil Visualisasi Clustering Data



Principal Component Analysis (PCA)

PCA

```
pca_features = pd.DataFrame(x_pca, columns=['pc'+str(i) for i in range(1, x_pca.shape[1]+1)])
# pca_features = pd.DataFrame(x_pca, columns=['pc1', 'pc2', 'pc3', 'pc4', 'pc5', 'pc6', 'pc7', 'pc8', 'pc9'])
pca_features
```

	pc1	pc2	pc3	pc4	pc5	pc6	pc7	pc8	pc9
0	0.101970	0.367834	0.459225	0.215321	-0.066374	0.277803	-0.276398	-0.075741	-0.281809
1	-0.276901	-0.296875	-0.055473	-0.075397	0.138937	-0.214574	-0.077367	-0.193858	-0.231176
2	-0.352116	0.043993	0.550623	-0.664983	0.027168	0.230081	-0.358410	0.137946	-0.074744
3	0.257026	-0.031011	-0.344450	0.469878	0.255150	0.115380	0.279650	0.487774	-0.161291
4	-0.267967	0.273591	0.226572	0.278404	0.000509	-0.039059	-0.330899	0.030845	-0.447973
...	...	...	...	...	...	...	...	...	...
994	-0.507107	0.186042	-0.168130	-0.150882	-0.262418	0.152777	-0.153947	0.132009	0.385946
995	0.235064	-0.087320	0.479353	0.168244	0.169942	0.564230	-0.298672	0.340461	0.250227
996	0.428570	0.116822	-0.314305	0.129191	0.141540	-0.067682	-0.213980	-0.295610	-0.138589
997	0.538126	-0.472184	0.333496	0.217536	0.026428	0.120408	0.209934	0.322058	0.244843
998	0.184360	-0.110541	-0.250078	-0.295281	-0.299040	0.433627	-0.604354	0.052631	0.372916
999 rows × 9 columns									



PCA

```
df_minmax_vars = df_minmax.var()
```

```
print(df_minmax_vars)
```

```
PM2.5      0.084514
PM10       0.082857
NO2        0.084779
SO2        0.083019
CO         0.083392
O3         0.080112
Temperature 0.081269
Humidity    0.084864
Wind Speed  0.085591
dtype: float64
```

```
df_minmax_vars
```

```
0
PM2.5      0.084514
PM10       0.082857
NO2        0.084779
SO2        0.083019
CO         0.083392
O3         0.080112
Temperature 0.081269
Humidity    0.084864
Wind Speed  0.085591
```

```
dtype: float64
```

```
-np.sort(-np.array([a/df_minmax_varsum for a in df_minmax_vars]))
```

```
array([0.11406121, 0.1130924 , 0.11297902, 0.11262501, 0.11113098,
        0.11063391, 0.11041696, 0.10830106, 0.10675946])
```

PCA

```
X = data_filtered[['Temperature', 'Humidity', 'Wind Speed']]
Y = data_filtered[['PM2.5', 'PM10', 'NO2', 'SO2', 'CO', 'O3']]

from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score
```

```
# Loop setiap polutan (Y.columns)
for pollutant in Y.columns:
    # Inisialisasi model regresi
    model = LinearRegression()

    # model fit menggunakan suhu dan kecepatan angin sebagai fitur
    model.fit(X, Y[pollutant])

    # Prediksi nilai polutan berdasarkan X
    predictions = model.predict(X)

    # Hitung R2 Score
    r2 = r2_score(Y[pollutant], predictions)

    # Simpan hasil
    results[pollutant] = {
        'R2 Score': r2,
        'Coefficients': model.coef_,
        'Intercept': model.intercept_
    }
```



PCA

```
# Format hasil ke dalam DataFrame untuk mempermudah pembacaan
results_df = pd.DataFrame({
    'Pollutant': results.keys(),
    'R2 Score': [res['R2 Score'] for res in results.values()],
    'Temperature Coefficient': [res['Coefficients'][0] for res in results.values()],
    'Humidity Coefficient': [res['Coefficients'][1] for res in results.values()],
    'Wind Speed Coefficient': [res['Coefficients'][2] for res in results.values()],
    'Intercept': [res['Intercept'] for res in results.values()]
})
```

results_df

	Pollutant	R2 Score	Temperature Coefficient	Humidity Coefficient	Wind Speed Coefficient	Intercept
0	PM2.5	0.007284	-0.217175	-0.066251	-0.066251	84.784116
1	PM10	0.004755	0.006346	0.086773	0.086773	97.573885
2	NO2	0.001990	0.046462	0.035361	0.035361	48.561692
3	SO2	0.001607	-0.037416	0.001297	0.001297	25.263359
4	CO	0.003767	-0.010898	0.002069	0.002069	5.301437
5	O3	0.005217	0.011066	0.052691	0.052691	111.837081

PCA

- ✓ R^2 Score Definisi Mengukur seberapa baik model menjelaskan variansi data polutan berdasarkan suhu, kelembapan, dan kecepatan angin.
- ✓ Temperature Coefficient : Mengukur seberapa besar pengaruh Temperature terhadap tingkat polutan
- ✓ Humidity Coefficient : Mengukur pengaruh Humidity terhadap tingkat polutan.
- ✓ Wind Speed Coefficient : Mengukur pengaruh Wind Speed terhadap tingkat polutan.
- ✓ Intercept : Nilai dasar tingkat polutan ketika semua faktor (Temperature, Humidity, Wind Speed) bernilai nol.



Identified Data Each Clustering

Identifikasi Polusi Tertinggi

```
# Hitung total polusi untuk semua baris
pollutants = ['PM2.5_x', 'PM10_x', 'NO2_x', 'SO2_x', 'CO_x', 'O3_x']
df['Total_Pollution'] = df[pollutants].sum(axis=1)

# Tentukan baris yg memiliki nilai maks total polusi
max_pollution_row = df.loc[df['Total_Pollution'].idxmax()]

return max_pollution_row['Country'], max_pollution_row['City'], max_pollution_row['Total_Pollution']

country, city, max_pollution = find_highest_pollution(df_clustered)
print(f"The country and city with the highest overall pollution is: {country}, {city} with a total pollution of {max_pollution:.2f}")
```

The country and city with the highest overall pollution is: Germany, Berlin with a total pollution of 612.83



Identifikasi Polutan

```
# Cari polutan dengan rata rata tertinggi di cluster
cluster_0_data = df_clustered[df_clustered['Cluster'] == 0]
pollutants = ['PM2.5_x', 'PM10_x', 'NO2_x', 'SO2_x', 'CO_x', 'O3_x']
avg_pollution_cluster_0 = cluster_0_data[pollutants].mean()
highest_pollutant = avg_pollution_cluster_0.idxmax()
max_pollutant_value = avg_pollution_cluster_0.max()

# Tentukan baris yang memiliki highest value untuk dari polutan tertinggi
max_pollutant_row = cluster_0_data.loc[cluster_0_data[highest_pollutant] == cluster_0_data[highest_pollutant].max()]

print(f"The highest average pollutant in cluster 0 is {highest_pollutant} with an average value of {max_pollutant_value:.2f}")

# Print
if not max_pollutant_row.empty:
    print(f"Country and city with the maximum {highest_pollutant} ({cluster_0_data[highest_pollutant].max():.2f}) in cluster 0:")
    for index, row in max_pollutant_row.iterrows():
        print(f"Country: {row['Country']}, City: {row['City']}")
else:
    print("No data found for the maximum pollutant in cluster 0.")
```

- Cluster 0: PM10 (193.67) di South Africa, Johannesburg.
- Cluster 1: PM10 (199.54) di South Africa, Johannesburg.
- Cluster 2: PM2.5 (149.74) di USA, Los Angeles.
- Cluster 3: O3 (196.21) di Canada, Toronto.
- Cluster 4: PM10 (198.93) di Brazil, Rio de Janeiro.
- Cluster 5: PM10 (199.28) di France, Paris.
- Cluster 6: O3 (199.32) di South Korea, Seoul.

Clustering on Principal Components

PCA All Features

```
KMeans
KMeans(init='random', n_clusters=7, n_init=10, random_state=42)
```

```
# The lowest SSE value
print(kmeans_pca_all.inertia_)

# Final locations of the centroid
print(kmeans_pca_all.cluster_centers_)

# The number of iterations required to converge
print(kmeans_pca_all.n_iter_)
```

```
534.0645018343781
[[ 0.1325977 -0.16150032 -0.00854037  0.29275436 -0.11652704 -0.16618307
    0.11553215 -0.16618439 -0.07925801]
 [ 0.00836377  0.33324559  0.06878849 -0.14934992  0.09320361 -0.17314317
   -0.00652474 -0.18262646  0.04701497]
 [ 0.3250514 -0.07190148 -0.10411451 -0.20623232 -0.18635431  0.0406981
   -0.0430141  0.10331253  0.01562142]
 [ 0.09041866 -0.10926737  0.26010661 -0.02889619  0.2347253  0.23147537
   -0.00489165 -0.03424338  0.0082059 ]
 [ 0.03927626  0.01982251 -0.28609969  0.04562187  0.25281263 -0.03788116
    0.03551896  0.25733784  0.00452932]
 [-0.22939714  0.2280789  0.0449662  0.18837605 -0.21372961  0.13582158
   -0.10334958  0.03761661  0.02092522]
 [-0.37267482 -0.25827048 -0.03363189 -0.11312776 -0.04612718 -0.06945994
    0.02574537  0.0089775 -0.02552968]]
32
```


First PCA

```
KMeans
KMeans(init='random', n_clusters=7, n_init=10, random_state=42)
```

```
# The lowest SSE value
print(kmeans_pca_first.inertia_)

# Final locations of the centroid
print(kmeans_pca_first.cluster_centers_)

# The number of iterations required to converge
print(kmeans_pca_first.n_iter_)
```

```
3.7130528155521283
[[-0.31902044]
 [ 0.59772296]
 [ 0.02588944]
 [-0.56878476]
 [ 0.36145221]
 [-0.13059262]
 [ 0.19021045]]
20
```

First Two PCA

```
KMeans  
KMeans(init='random', n_clusters=7, n_init=10, random_state=42)
```

```
# The lowest SSE value  
print(kmeans_pca_first2.inertia_)  
  
# Final locations of the centroid  
print(kmeans_pca_first2.cluster_centers_)  
  
# The number of iterations required to converge  
print(kmeans_pca_first2.n_iter_)
```

```
38.431750823244556  
[[ 0.02118747 -0.00203924]  
 [-0.19092652 -0.34600451]  
 [ 0.24285216 -0.38032225]  
 [-0.25479234  0.3424513 ]  
 [ 0.46370122  0.01513421]  
 [ 0.18672102  0.40296915]  
 [-0.46685251 -0.04871742]]  
27
```

First Three PCA

```
KMeans
KMeans(init='random', n_clusters=7, n_init=10, random_state=42)
```

```
# The lowest SSE value
print(kmeans_pca_first3.inertia_)

# Final locations of the centroid
print(kmeans_pca_first3.cluster_centers_)

# The number of iterations required to converge
print(kmeans_pca_first3.n_iter_)
```

```
97.58638426622052
[[ 0.14891974 -0.20128243 -0.34174502]
 [ 0.37750452  0.17025961 -0.14081548]
 [ 0.25084943 -0.27383173  0.23901701]
 [ 0.08845557  0.3415565   0.24698965]
 [-0.24485668  0.2849846  -0.20114834]
 [-0.2982493   -0.26711275 -0.06229174]
 [-0.23802371 -0.02574691  0.3551705  ]]
25
```

Perbandingan Data

```
from sklearn.metrics import v_measure_score
```

```
v_measure_score(kmeans.labels_, kmeans_pca_all.labels_)
```

```
1.0
```

```
v_measure_score(kmeans.labels_, kmeans_pca_first.labels_)
```

```
0.17116071571811828
```

```
v_measure_score(kmeans.labels_, kmeans_pca_first2.labels_)
```

```
0.24012785684440524
```

```
v_measure_score(kmeans.labels_, kmeans_pca_first3.labels_)
```

```
0.2629749246558389
```

Membandingkan hasil clustering antara data yang telah dinormalisasi dengan data hasil PCA menggunakan semua komponen, satu komponen pertama, dua komponen pertama, dan tiga komponen pertama.

Kesimpulan

Proses analisis data dimulai dengan Data Cleaning untuk memastikan kualitas data, menghapus data yang tidak valid, kosong, atau tidak relevan. Setelah itu, atribut yang paling relevan dipilih, dan data dinormalisasi untuk mengurangi variabilitas yang ekstrem (outlier). Teknik Principal Component Analysis (PCA) digunakan untuk mengurangi dimensi data, diikuti oleh K-Means Clustering untuk mengelompokkan data berdasarkan kesamaan fitur.

Hasil analisis menunjukkan bahwa faktor cuaca seperti kecepatan angin (wind speed), suhu (temperature), dan kelembapan udara (humidity) memiliki pengaruh yang sangat kecil terhadap variansi konsentrasi polutan utama (PM10, PM2.5, NO2, CO, dan O3). Hal ini ditunjukkan oleh nilai R^2 yang rendah.

Berdasarkan analisis juga diperoleh bahwa setiap cluster memiliki dominasi polutan yang berbeda, mencerminkan variasi aktivitas manusia, sumber emisi lokal, dan faktor geografis. PM10 menjadi polutan dominan di wilayah seperti Johannesburg, Rio de Janeiro, dan Paris, sementara PM2.5 mencatatkan rata-rata tertinggi di Los Angeles, dan O3 mendominasi di Toronto dan Seoul. Dan secara keseluruhan, negara dan kota dengan tingkat polusi tertinggi adalah Jerman (Berlin) dengan total konsentrasi polutan sebesar 612.83.



THANK YOU

